2026년도 머신러닝 서비스 개발 프로젝트

AI개발 수행내역서

수원시 버스 정류장별
일일 승차 수요 예측 및 시각화 서비스

담당자 강현수

2026년 10월 29일

I. AI개발 수행내용

1. 사업과제

수원시 버스 정류장별 일일 승차 수요 예측 및 시각화 서비스

정류소ID와 날짜를 입력하면 해당 정류소의 하루 승차 인원을 예측하는 머신러닝 시범 서비스를 구축하였다. 최종 Ridge Regression은 2026년 8월 3,100건에서 MAE 218.860명, RMSE 299.136명, R^2 0.9387을 기록하였다. 예측 결과와 과거 수요 패턴은 Streamlit 화면에서 함께 확인할 수 있다.

2. 개요 및 현황

2.1 추진배경 및 목적

정류소별 일일 승차 집계에는 지역별 이용 규모와 요일별 패턴이 함께 담겨 있다. 전체 관측을 단순 합계로만 보면 정류소마다 다른 수요 수준과 날짜에 따른 변화를 구분하기 어렵다. 본 과제는 이러한 관측을 분석하고, 정류소와 날짜만으로 일일 승차 인원을 추정하는 과정을 구현하는 데 목적을 두었다.

평균값을 반환하는 기준 모델과 선형·비선형 회귀 모델을 동일한 시간 구간에서 비교하여 모델 선택의 근거를 확보하였다. 저장된 전처리와 모델을 서비스에서 그대로 사용함으로써 분석 결과를 실제 입력·예측·시각화로 연결하였다. 배차 최적화나 운영비 절감 효과는 이번 과제에서 측정하지 않았다.

2.2 과제 범위

표 1. 과제 수행 범위

구분	구현 범위
데이터	2026년 6–8월 수원시 관측 129,049건과 1,435개 정류소의 구조·품질 확인
분석 대상	6–7월 관측일 55일 이상 정류소 중 같은 기간 승차합계 상위 100개
머신러닝	정류소ID와 날짜 기반 회귀, 시간 분할, 세 후보 비교, 최종 모델 저장·평가
서비스	정류소·날짜 선택, 일일 승차 예측, 일별·요일별 수요 패턴과 성능 표시
범위 밖	시간대별 수요, 차량 혼잡도, 노선·배차 최적화, 실시간 수집 및 인과효과 분석

관측 단위는 정류소ID와 날짜의 조합이며, 예측 단위는 명/정류소·하루이다.

2.3 과제 추진 방법

1) 구축 대상 선정 기준

제공된 공공 승하차 집계는 목표 변수인 승차합계와 날짜·정류소 식별자를 포함하므로 일일 수요 회귀에 적합하였다. 92일의 관측 여부를 확인하고, 데이터 규모와 빠른 재현을 고려해 고수요 정류소 100개를 MVP 대상으로 제한하였다. 동일한 정류소명이 서로 다른 ID에 연결될 수 있어 식별 기준은 정류소ID로 정하였다.

2) AI 예측 분석모델 적용 대상

표 2. 예측 문제의 정의

항목	정의
예측 대상	선정된 정류소의 특정 날짜 하루 승차합계
사용자 입력	정류소ID, 예측 날짜
모델 특성	정류소 범주와 날짜에서 만든 요일·주말 여부·월·일
출력 및 활용	0명 이상으로 제한한 일일 승차 추정치와 과거 관측 패턴

3) AI 분석모델 구축 프로세스

원본 구조·품질 확인 → 대상 100개 선정 → 관측 수요 EDA → 시간 분할 → 전처리 Pipeline과 세 후보 학습 → 7월 MAE로 선택 → 6–7월 최종 재학습 → 8월 평가 → 모델 저장 → Streamlit 서비스 구현 순으로 진행하였다.

후보 모델은 6월 자료로만 학습하고 7월 자료로 비교하였다. 최종 후보를 확정한 후 6–7월 6,100건으로 재학습하고 8월 3,100건의 예측을 생성하였다. 성능 표·그래프·서비스에 표시되는 지표는 이 저장된 결과를 공유한다.

결과성 변수 차단과 학습 구간 내 전처리 학습으로 누수를 줄였다. 다만 정류소 대상 선정에는 7월 관측을 포함하므로 7월 검증은 대상 선정과 완전히 독립적이지 않다. 8월 관측은 대상 선정·후보 선택·재학습에 사용하지 않았다.

4) 구현 및 실행환경

기존 학습 산출물에는 Python 3.12.6, pandas 2.3.3, NumPy 2.5.4, scikit-learn 1.8.0, joblib 1.6.0이 기록되어 있다. 앱은 Streamlit 1.66.1을 사용한다. 학원 PC와 집 PC에서 프로젝트를 실행하였으며, 집 PC는 Python 3.12.10에서 requirements 설치와 실제 예측 버튼 동작을 확인하였다.

실행환경과 패키지 버전의 근거: README.md, requirements.txt, outputs/metrics.json. 집 PC의 기존 자동 검증 결과는 outputs/validation.json에 기록되어 있다.

II. 연구개발 주요 결과물

1. 데이터 수집

데이터 출처는 경기데이터드림의 경기도 정류소별 승하차 인원 집계이다. 프로젝트는 제공받은 수원시 CSV를 사용하였다. 관측 기간은 2026년 6월 1일부터 8월 31일까지 92일이며, 129,049건·9개 컬럼·1,435개 정류소ID로 구성되어 있다.

원본 파일은 suwon_bus_boardings_202606_202608.csv이며 읽기 전용으로 사용하였다. 원천 데이터는 경기데이터드림의 '경기도 정류소 별 승하차 인원 집계'이며, 2026년 10월 29일에 6월부터 8월까지의 월별 자료를 확보하였다. 수원시 관측값을 추출·통합하여 머신러닝 분석용 CSV를 구성하였다. 제공기관은 경기도이며 갱신 주기는 월간이다. 데이터 제공 페이지에는 상업적 이용 및 콘텐츠 변경이 허용되는 것으로 표시되어 있다.

2. 데이터 분석

2.1 데이터 구조 및 품질

표 3. 원본 데이터의 컬럼과 사용 목적

컬럼	자료형·단위	사용 목적
승하차일자	날짜	날짜 입력 및 파생 특성 생성
관할관청	문자열	모든 관측이 수원시인지 확인
정류소ID	문자열	정류소 식별 및 모델 입력
정류소번호	문자열	선행 0 보존, 서비스 표시
정류소명	문자열	서비스 표시와 선택 보조
승차합계	정수·명	예측 목표이며 입력에서 제외
초승	정수·명	최초 승차 관측값, 입력에서 제외
환승	정수·명	환승 관측값, 입력에서 제외
하차	정수·명	하차 관측값, 입력에서 제외

표 4. 원본 품질 검사 결과

검사 항목	실제 결과
결측치 / 정류소·날짜 중복 / 음수 인원	모두 0건
관할관청 및 관측 범위	모든 행 수원시, 지정된 92일 이내
승차합계 0명인 관측	5,481건, 실제 관측으로 유지
전체 정류소×92일 대비 미관측 조합	2,971개, 0명으로 채우지 않음
원본 보존 확인	CRLF를 LF로 정규화하면 Git 원본과 바이트 전체 일치

자료: outputs/metrics.json의 quality, 분석 노트북의 품질 검사 결과. Windows의 줄바꿈 차이는 메모리에서만 정규화하며 CSV 파일은 변경하지 않는다.

2.2 탐색적 데이터 분석 EDA

대상 100개 정류소의 실제 관측 9,200건을 월별·요일별로 집계하였다. 모든 선정 정류소는 6–7월 61일과 8월 31일이 관측되었다. 아래 결과는 이 고수요 집합에 한정되며 수원시 전체 이용량으로 해석하지 않는다.

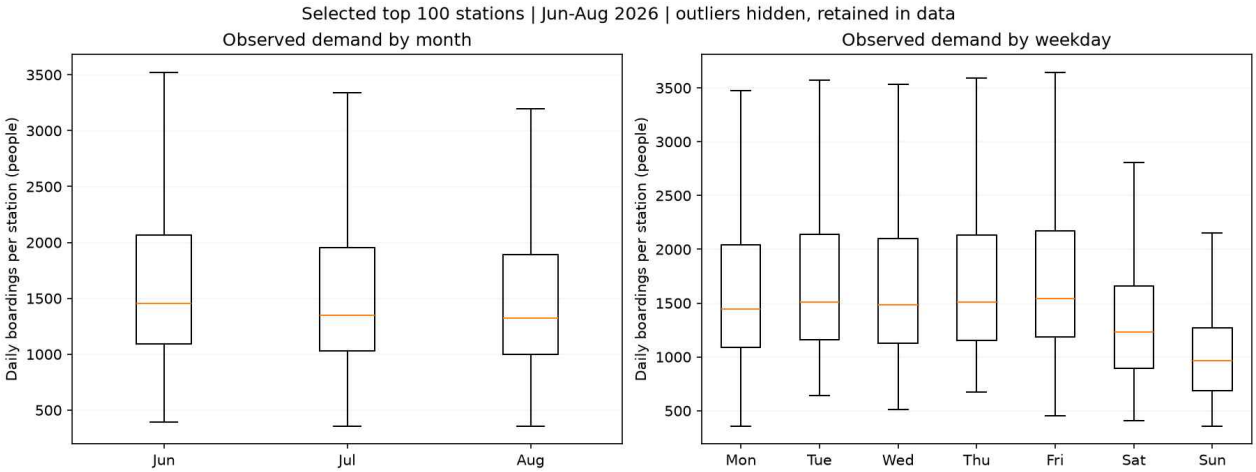


그림 1. 상위 100개 정류소의 월별·요일별 승차 인원 분포

단위: 명/정류소·하루. 상자그림의 극단점은 표시만 생략하였으며 데이터에서는 제외하지 않았다. 자료: 분석 노트북과 기존 EDA 그림.

표 5. 선정 정류소의 월별 관측 수요

월	관측 건수	총 승차 인원	관측일 평균	중앙값
6월	3,000	5,440,764	1,813.59	1,457
7월	3,100	5,316,887	1,715.12	1,350
8월	3,100	5,181,274	1,671.38	1,321

총합의 단위는 명, 평균과 중앙값은 명/정류소·관측일이다. 월별 일수가 달라 총합과 관측일 평균을 함께 제시하였다.

표 6. 요일별 관측일 평균 승차 인원

월	화	수	목	금	토	일
1,795.80	1,882.73	1,841.47	1,880.52	1,930.35	1,563.72	1,227.98

관측일 평균은 6월 1,813.59명에서 7월 1,715.12명, 8월 1,671.38명으로 낮아졌다. 요일별로는 금요일 평균 1,930.35명, 일요일 평균 1,227.98명으로 이 집합에서는 일요일 수요가 낮았다. 기상·방학·공휴일 등 원인은 검증하지 않았으므로 인과관계를 주장하지 않는다.

8월 EDA는 관측 결과를 설명하기 위한 기술 분석이다. 8월의 집계값을 정류소 순위, 입력 특성, 후보 선택 또는 튜닝에 반영하지 않았다.

2.3 데이터 전처리

1) 자료형 변환과 관측 보존

정류소ID와 정류소번호는 문자열로 읽어 식별자의 의미와 선행 0을 보존하였다.
승하차일자는 날짜형으로 변환하고, 정류소ID와 날짜의 조합이 중복되지 않는지 확인하였다.
결측치·중복·음수가 없으므로 이를 이유로 행을 삭제하거나 값을 대체하지 않았다.

승차 인원이 실제로 0명인 관측은 유지하였다. 관측 자체가 없는 날짜는 0명과 의미가 다르므로 전체 조합을 재색인해 채우지 않았다. 큰 승차합계도 이상치라는 이유만으로 학습·평가에서 제거하지 않았다.

2) 대상 정류소 선정

6–7월 자료에서 관측일이 55일 이상인 정류소를 남긴 뒤 같은 기간 승차합계를 내림차순으로 정렬하였다. 동률이면 ID 오름차순으로 정렬하여 상위 100개를 확정하였다.
정류소명·번호도 6–7월 관측에서 가져와 8월 정보가 대상 선정이나 메타데이터 구성에 섞이지 않도록 하였다.

3) 입력 특성과 제외 변수

표 7. 모델 입력의 생성과 변환

입력 특성	생성 기준	변환 방법
정류소	정류소ID를 문자열로 사용	OneHotEncoder
요일	월요일 0부터 일요일 6까지 생성 후 범주로 사용	OneHotEncoder
주말 여부	토요일·일요일이면 1, 그 외 0	StandardScaler
월	예측 날짜의 월	StandardScaler
일	예측 날짜의 일	StandardScaler

사용자 입력은 정류소ID와 날짜 두 값이다. 날짜에서 파생한 특성은 예측 시점에 알 수 있는 값만 사용한다. 정류소ID의 숫자 크기에는 연속적인 거리 의미를 부여하지 않는다.
정류소명·번호는 화면 표시용이며 학습 입력이 아니다.

당일 승차합계는 예측 목표이며, 초승(최초 승차)·환승·하차도 당일 결과성 관측이다. 이들 값을 입력하면 예측 시점에 알 수 없는 정보가 유입될 수 있으므로 모두 차단하였다.
make_features는 허용한 입력만 읽고, 앱도 정류소ID와 날짜만 전달한다.

구현 근거: train.py의 load_data, select_stations, make_features 및 app.py의 예측 요청 구성.

3. 데이터 학습 및 모델 정의

3.1 머신러닝 모델 정의

정류소별 하루 승차 인원을 연속적인 수치로 예측하는 회귀 문제로 정의하였다. 동일한 전처리와 시간 구간을 적용하여 기준 모델, 규제 선형 모델, 비선형 트리 앙상블을 비교하였다.

표 8. 비교 모델과 주요 설정

모델	역할과 설정
Dummy Regressor	학습 승차합계의 평균을 예측하는 기준 모델, strategy=mean
Ridge Regression	L2 규제를 사용하는 선형 회귀, alpha=1.0
Random Forest Regressor	n_estimators=60, max_depth=20, min_samples_leaf=3, random_state=42, n_jobs=2

Random Forest는 학습 시간·메모리·모델 크기를 고려해 복잡도를 제한하였다. 대규모 GridSearch나 추가 하이퍼파라미터 탐색은 수행하지 않았다. 따라서 비교 결과는 이 고정된 설정에 대한 결과이다.

3.2 전처리 Pipeline 및 학습

FunctionTransformer로 날짜 특성을 생성하고, ColumnTransformer로 범주형 인코딩과 수치형 표준화를 수행한 뒤 회귀 모델에 연결하였다. OneHotEncoder는 handle_unknown=ignore를 사용한다. 전체 Pipeline을 joblib으로 저장해 학습과 서비스 예측에 동일한 변환을 적용하였다.

표 9. 학습·검증·최종 테스트 기간

구분	2026년 기간	건수	사용 목적
Train	6월 1일부터 6월 30일	3,000	후보 모델과 전처리 학습
Validation	7월 1일부터 7월 31일	3,100	후보별 MAE 비교 및 선택
최종 재학습	6월 1일부터 7월 31일	6,100	선정 모델과 전처리 다시 학습
Test	8월 1일부터 8월 31일	3,100	확정한 최종 모델 평가

무작위 분할을 하지 않았다. 후보별 전처리와 모델은 6월에서만 fit하고 7월에는 transform과 predict를 적용하였다. 7월 MAE가 가장 낮은 후보를 정한 뒤 6–7월에 재학습하였다. 8월 테스트는 최종 선택 이후 보존된 구간으로 평가하였다.

정류소 선정을 위한 6–7월 집계에 검증월이 포함되므로 7월 검증은 정류소 대상 선정과 완전히 독립적이지 않다. 모델 성능을 일반화하려면 이후 별도 기간에서 추가 평가가 필요하다.

3.3 모델별 성능 비교

MAE는 한 정류소·하루당 절대 오차의 평균이며 모델 선정 기준이다. RMSE는 큰 오차에 더 민감한 지표이고, R^2는 관측값의 분산 대비 설명력을 나타내는 무단위 지표이다. MAE·RMSE는 낮을수록 좋고 R^2는 높을수록 좋다.

표 10. 6월 학습 후보의 성능 비교

모델	평가 구간	MAE 명	RMSE 명	R^2
Dummy	6월 학습	814.095	1,279.195	0.0000
Dummy	7월 검증	815.271	1,225.172	-0.0065
Ridge	6월 학습	193.889	274.989	0.9538
Ridge	7월 검증	215.933	297.517	0.9406
Random Forest	6월 학습	302.480	376.343	0.9134
Random Forest	7월 검증	329.460	398.001	0.8938

자료: outputs/metrics.json의 candidate_metrics, outputs/model_comparison.csv 및 노트북 저장 결과. 후보들은 모두 6월에만 학습하였다.

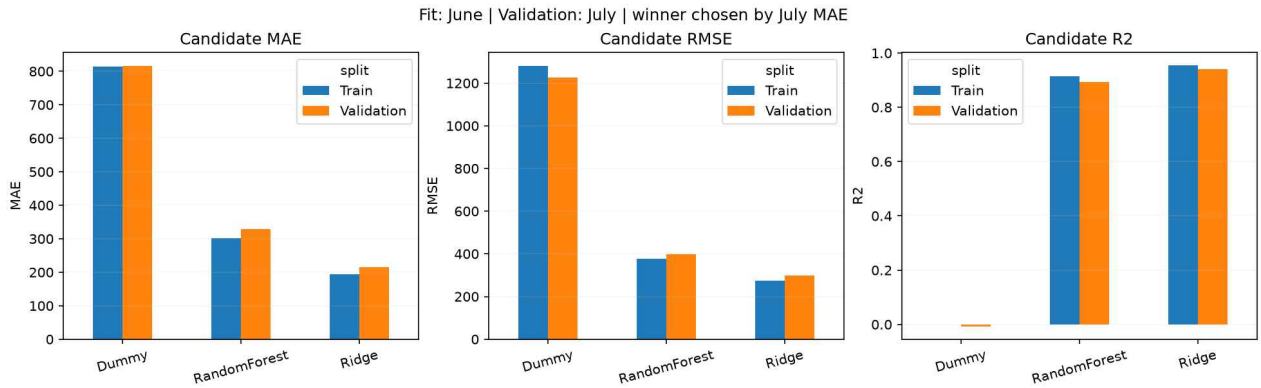


그림 2. 후보 모델의 학습·검증 지표 비교

학습은 6월, 검증은 7월이다. 그림과 표는 동일한 기존 후보 평가 결과를 사용하였다.

7월 검증 MAE는 Dummy 815.271명, Ridge 215.933명, Random Forest 329.460명이었다. 기준 모델보다 오차가 낮고 검증 MAE가 가장 작은 Ridge Regression을 최종 후보로 선정하였다. Ridge의 검증 RMSE는 297.517명, R^2는 0.9406이었다.

Ridge의 학습 MAE 193.889명과 검증 MAE 215.933명은 차이가 있으므로 학습 적합도와 검증 성능을 구분하였다. Random Forest의 이번 설정은 Ridge보다 오차가 높았지만, 다른 하이퍼파라미터나 추가 특성에서도 같은 우열이 유지된다고 일반화하지 않는다.

평가 전 모든 예측을 0명 이상으로 제한하였다. 평가값은 반올림하지 않고 지표를 계산하며, 서비스 화면에서만 정수로 반올림한다. R^2를 정답 비율이나 정확도 백분율로 해석하지 않는다.

3.4 실제값과 예측값 비교

선정된 Ridge를 6–7월 6,100건에 재학습하고 8월 3,100건에서 최종 평가하였다. 저장 기록의 test_evaluation_count는 1이며, 성능 표와 그림은 같은 최종 테스트 예측을 사용한다.

표 11. 최종 Ridge의 재학습·테스트 성능

구간	MAE 명	RMSE 명	R^2
6–7월 최종 재학습	182.972	269.904	0.9535
8월 최종 테스트	218.860	299.136	0.9387

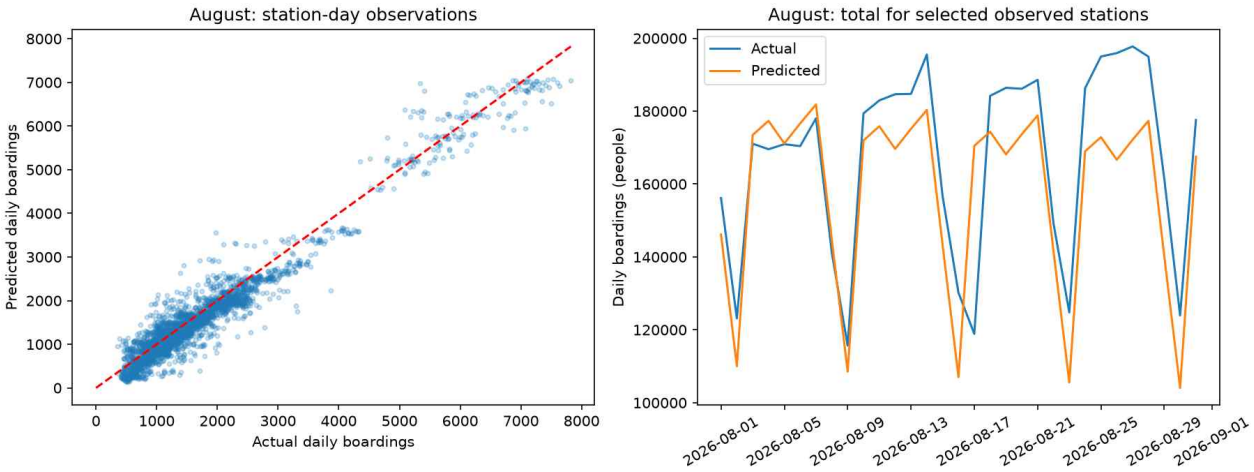


그림 3. 8월 실제 승차 인원과 최종 예측값 비교

왼쪽은 정류소·날짜 관측별 실제값과 예측값, 오른쪽은 대상 정류소의 날짜별 합계이다. 자료: outputs/test_predictions.csv와 기존 평가 그림.

표 12. 저장된 최종 테스트 예측의 첫 3개 관측

날짜	정류소ID	실제 명	예측 명
2026-08-01	200000069	602	693.372
2026-08-01	200000080	1,532	1,702.743
2026-08-01	200000088	2,271	1,606.630

최종 MAE 218.860명은 이번 테스트에서 한 정류소·하루당 절대 오차가 평균 약 219명이라는 뜻이다. 특정 정류소의 개별 예측마다 이 범위가 보장되는 것은 아니다. 재학습 성능은 이미 학습한 데이터에 대한 적합도이므로 미래 성능과 구분한다.

산점도에는 일부 고수요 관측을 낮게 예측한 지점이 있고, 일별 합계에서도 과소추정이 남아 있다. 높은 전체 R^2에는 정류소 간 평균 수요 규모 차이를 설명하는 효과도 포함된다. 개별 정류소의 날짜별 변동을 같은 수준으로 맞춘다고 해석할 수 없다.

표 11의 지표는 저장된 3,100개 예측값으로 다시 계산해 JSON과 일치함을 확인하였다. 모델을 다시 학습하거나 예측 파일을 덮어쓰지 않았다.

4. 프로토타이핑

4.1 Streamlit 예측 서비스

저장된 Ridge Pipeline과 정류소 목록·과거 관측·평가 JSON을 읽어 예측 서비스를 구현하였다. 정류소명·번호·ID가 함께 표시된 100개 선택지와 날짜 입력을 제공하고, 예측 버튼을 누르면 예상 일일 승차 인원을 표시한다.

서비스: https://suwon-bus-demand.streamlit.app

GitHub: https://github.com/gustn0307/suwon-bus-demand-ml



그림 4. 실제 배포 서비스의 입력과 예측 결과

2026년 10월 29일 실제 서비스 캡처. 수원역7번출구.AK플라자, 번호 03017, ID 202000219, 예측 날짜 2026년 9월 1일의 표시값은 6,950명이다.

사용 절차는 정류소 선택, 날짜 선택, 일일 승차 인원 예측 버튼 실행의 순서이다. 같은 이름의 정류소도 ID와 번호를 함께 확인하여 구분한다. 표시값은 정수로 반올림한 추정치이며 차량별 혼잡도나 시간대별 탑승 인원이 아니다.

학습 마지막 날짜인 2026년 7월 31일 이후에는 제한적 추정 안내를 표시한다. 그림 4의 9월 1일 예측은 학습·테스트 기간 밖의 서비스 시연이며, 해당 날짜의 실측값과 비교한 성능을 의미하지 않는다.

4.2 예측 결과 및 시각화

선택 정류소의 6–8월 일일 승차합계를 선 그래프로, 요일별 관측 평균을 막대 그래프로 보여준다. 이 차트는 과거 관측을 설명하며 8월 값이 모델 입력으로 전달되는 것은 아니다. 관측이 누락된 날짜를 임의로 0명으로 채우지 않는다.



그림 5. 실제 서비스의 요일별 수요와 최종 테스트 성능

같은 정류소의 요일별 관측 평균과 최종 MAE 218.860명·RMSE 299.136명·R^2 표시를 확인하였다. 앱의 R^2 0.939는 소수 셋째 자리 표시이며 보고서의 0.9387과 같은 원값이다.

화면 하단에는 최종 모델명, 대상 정류소 수, 8월 평가 건수와 MAE·RMSE·R^2를 함께 제시한다. 사용자가 개별 예측값과 모델 전체의 평가 결과를 구분하고, 여름 관측에 한정된 추정임을 이해하도록 안내하였다.

서비스 및 산출물 검증

기존 outputs/validation.json에는 6개 테스트 통과, 실패 0·오류 0과 Streamlit health 응답 ok, 루트 페이지 HTTP 200이 기록되어 있다. 검사 범위는 원본·관측 보존, 8월 변경에 대한 대상 선정 불변, 결과성 변수 변경에 대한 입력·예측 불변, 저장 모델의 미래 예측·미지 범주 처리, 노트북·시간 분할 일관성, 앱 입력·예측 상호작용이다.

이번 보고서 작성에서는 노트북의 코드 6개 셀에 실행 결과가 저장되어 있고 오류 출력이 없음을 확인하였다. 평가 JSON·모델 비교 CSV·저장 예측을 대조하고, 실제 배포 서비스의 예측 버튼과 화면 표시를 확인하였다. 모델 재학습과 기존 산출물 변경은 수행하지 않았다.

4.3 서비스 한계와 개선 방향

1) 자료와 적용 대상의 한계

관측 기간은 2026년 여름 3개월이고 모델 학습은 6–7월 두 달이다. 다른 계절·연도의 추세를 학습하지 않았으며, 고수요 상위 100개 정류소를 중심으로 분석하였다. 수원시 전체·저수요·신규 정류소 또는 장기 미래 수요로 성능을 일반화할 수 없다.

2) 외부 요인과 검증 설계의 한계

기상, 공휴일, 방학, 행사, 노선 변경과 배차 변화는 입력에 포함하지 않았다. 날짜와 ID만으로 급격한 외부 변화를 반영하기 어렵다. 또한 7월이 정류소 선정 기준에 포함되므로 검증 성능의 독립성에 한계가 있다. 전체 R^2만으로 개별 정류소의 변동 예측 능력을 판단할 수 없다.

3) 서비스 해석과 개선 방향

현재 서비스는 일일 인원 점추정치를 제공하며 개별 예측구간, 시간대별 수요, 실시간 혼잡도 또는 실측 미래 성능을 제공하지 않는다. 화면에서 선택할 수 있는 날짜 범위가 장기 성능을 보장하지도 않는다.

후속 과제는 계절을 포함한 장기 관측과 외부 요인 확보, 정류소 선정을 더 이른 기간에 고정한 독립 검증, 새로운 기간의 성능 점검이다. 이후 정류소별 오차와 수요 규모별 편향을 검토하고, 운영 시점의 관측 변화에 따라 모델을 갱신하는 절차를 마련할 수 있다. 이러한 개선은 이번 구현 결과와 구분되는 향후 제안이다.

결과 및 자료 근거

본 과제는 공공 승하차 집계의 품질 확인부터 입력 특성 생성, 시간 분할, 회귀 모델 비교, 저장 모델의 서비스 예측까지 연결하였다. 최종 Ridge의 8월 MAE 218.860명·RMSE 299.136명·R^2 0.9387은 보존된 테스트 예측을 기준으로 산출한 결과이다.